PS2026 - UFRJ Analytica

PedalaRio - Segurança Cicloviária do Rio

SafePath Group

Autores do projeto: Caroline Yumi, Mariana Freitas, Pedro Portela e Yasmim Rodrigues

1. Descrição

Responsável pela seção: Mariana Freitas

Este relatório propõe o desenvolvimento de um site que visa auxiliar ciclistas do Rio de Janeiro a traçar rotas mais seguras ao analisar o uso de bicicletas no município, considerando o crescente número de acidentes entre usuários de bicicleta e a desigualdade na infraestrutura cicloviária entre regiões.

A ideia do protótipo do site surgiu diante da observação do cotidiano de moradores do Rio de Janeiro que compartilham do mesmo receio: circular livremente de bicicleta pela cidade. Com o aumento do meio de transporte cicloviário como forma de locomoção e frente à sua crescente importância no deslocamento diário dos cidadãos, desafios relacionados à segurança dos ciclistas no espaço urbano tornam-se ainda mais evidentes. A questão identificada foi a dificuldade de decidir possíveis trajetórias que desviem ao máximo dos riscos presentes no trânsito urbano vivenciados por usuários desse modal. O resultado é um limbo entre a pressa e a segurança, no qual os indivíduos podem deixar de buscar o caminho menos perigoso devido à correria da atualidade.

A partir do estudo de dados sobre acidentes de trânsito e da rede cicloviária da cidade, busca-se identificar locais de maior risco, ao observar ocorrências do passado e a atual infraestrutura presente. Assim, planeja-se uma plataforma digital capaz de identificar o nível de segurança de ruas e bairros, indicando rotas mais seguras para ciclistas com base em algoritmos que consideram fatores de risco, contribuindo para a mobilidade urbana e a segurança cicloviária. Entretanto, o projeto pode enfrentar limitações relacionadas à disponibilidade e atualização dos dados utilizados, além da dificuldade de representar mudanças no trânsito e na infraestrutura em tempo real.

Na prática, a proposta pode ser utilizada como uma ferramenta de apoio para ciclistas durante o planejamento de trajetos, indicando vias mais seguras com base em fatores como histórico de acidentes, índices de criminalidade, velocidade das vias e presença de infraestrutura cicloviária adequada. Dessa forma, usuários poderiam evitar regiões classificadas como de maior risco e optar por percursos potencialmente mais seguros, mesmo que ligeiramente mais longos.

Figura 1 - Diagrama do Pipeline do protótipo

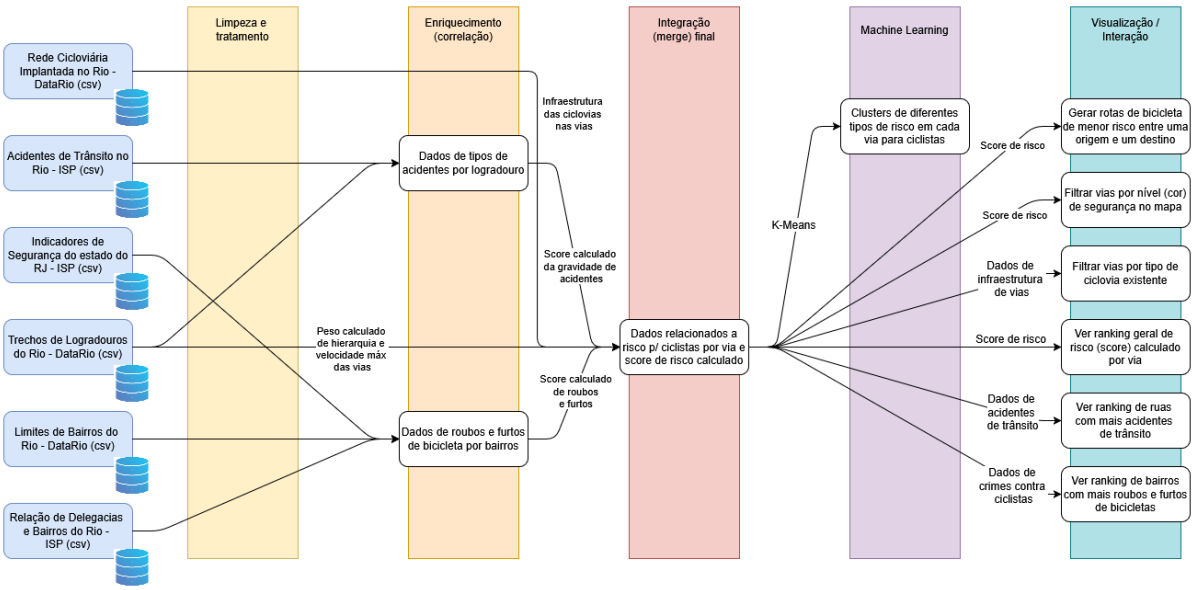

2. Objetivos

Responsáveis pela seção: Mariana Freitas e Caroline Yumi

2.1 Objetivo Geral

Desenvolver um protótipo de uma plataforma digital capaz de auxiliar ciclistas do Rio de Janeiro na identificação de rotas mais seguras, utilizando dados sobre acidentes de trânsito e infraestrutura cicloviária para contribuir com a mobilidade urbana e a segurança no deslocamento.

2.2 Objetivos específicos

1. Analisar dados relacionados à acidentes envolvendo ciclistas no município do Rio de Janeiro.
2. Identificar regiões com maior risco para os ciclistas.
3. Desenvolver um sistema capaz de sugerir trajetos mais seguros com base em fatores de risco previamente analisados e estabelecidos.

Figura 2 - Representação do fluxo funcional e das principais ferramentas da plataforma de segurança cicloviária

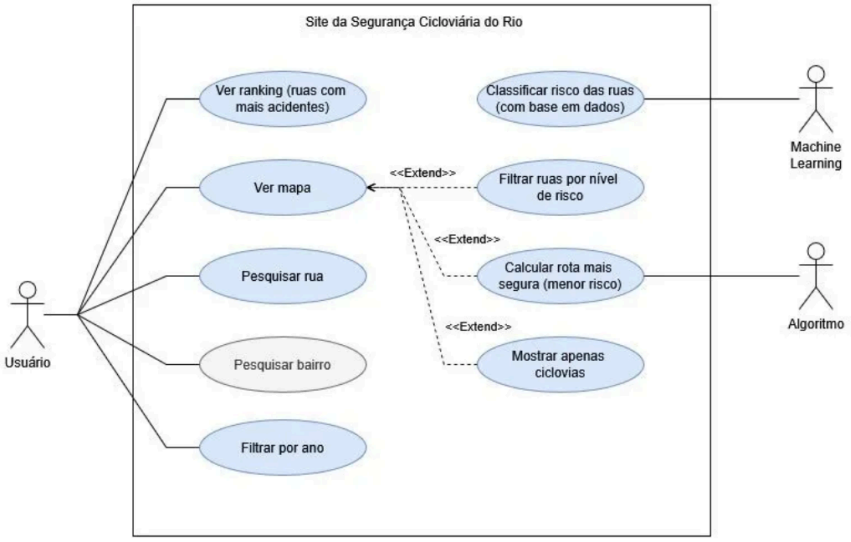

3. Dados utilizados

Responsáveis pela seção: Caroline Yumi, Mariana Freitas, Pedro Portela e Yasmim Rodrigues

Os dados utilizados neste projeto foram obtidos a partir de bases públicas relacionadas à mobilidade urbana, acidentes de trânsito, segurança pública e infraestrutura cicloviária no município do Rio de Janeiro.

As principais fontes incluem dados da plataforma Data.Rio, contendo informações sobre a rede cicloviária implantada, logradouros e limites territoriais dos bairros, bases do Zenodo com registros de acidentes envolvendo ciclistas entre 2018 e 2024, e dados do Instituto de Segurança Pública (ISP), com ocorrências de acidentes de trânsito, roubos e furtos de bicicletas e outros indicadores de segurança.

Esses dados apresentam diferentes tipos de informações, incluindo dados geoespaciais relacionadas a bairros, logradouros e à malha cicloviária, dados temporais referentes à distribuição dos registros ao longo dos anos, dados numéricos associados à quantidade de acidentes e ocorrências, e dados categóricos como tipo de acidente, tipo de via e infrações de trânsito.

O dataset de acidentes de trânsito contém registros de ocorrências associadas a diferentes tipos de delitos envolvendo vias da cidade do Rio de Janeiro que foram classificados por similaridade de caso pelo ISP, como acidentes e atropelamentos, entre 2019 e 2021, organizados por logradouro e tipo de ocorrência. A base bruta possui 1082 registros que foram copiados da tabela do site, visto que não havia link para download disponível.

A base de segurança pública reúne diversas informações relacionadas à criminalidade, sendo utilizados no projeto do site de segurança cicloviária apenas os dados de roubos e furtos de bicicletas, organizados por bairro e ano. Embora a base cubra o período de 2003 a 2026, na etapa de limpeza foram mantidos apenas os dados entre 2021 e 2025, tendo em vista que os anos anteriores estavam desatualizados e 2026 ainda não possui registros completos. Essas informações foram utilizadas para agregar taxas de criminalidade ao risco cicloviário. O total de linhas antes do

processamento é de 37589, com várias colunas que não seriam utilizadas nas próximas etapas do pipeline.

A base de logradouros contém informações detalhadas sobre as vias da cidade do Rio de Janeiro. Cada linha representa um trecho de logradouro contendo atributos relacionados à estrutura, destacando-se principalmente a hierarquia viária e velocidade máxima regulamentada. Esses dados foram utilizados para compor o índice de risco das vias, considerando, por exemplo, que uma via local com limite de velocidade elevado tende a oferecer menor segurança para ciclistas. Esse é o dataset mais extenso do projeto, contendo 132075 registros. Embora tenha sido considerada a utilização da versão em GeoJSON da base, optou-se pelo formato CSV devido à maior simplicidade de manipulação e ao escopo limitado do projeto.

A base da rede cicloviária reúne informações sobre as vias utilizadas por ciclistas e a infraestrutura cicloviária implantada na cidade do Rio de Janeiro. Foram utilizadas variáveis relacionadas ao tipo de infraestrutura, ao fluxo da via e a um índice de segurança da infraestrutura calculado separadamente. Com 576 registros, essa será a principal tabela empregada no cálculo do score de risco e na classificação do nível de segurança das vias, por concentrar informações estruturais diretamente relevantes para a mobilidade dos ciclistas na cidade.

Algumas tabelas auxiliares foram utilizadas apenas para o tratamento dos dados. Uma delas foi o dataset do ISP, que relaciona os códigos das delegacias do Rio de Janeiro aos respectivos bairros e regiões, permitindo mapear os dados da tabela de indicadores de segurança, que originalmente apresentavam as ocorrências apenas por delegacia, sem detalhamento por bairro. Além disso, foi utilizada outra tabela do ISP contendo os bairros do município, com o objetivo de filtrar somente os registros referentes ao município do Rio de Janeiro na base de indicadores de segurança, que abrange dados de todo o estado.

Etapas do pré-processamento

Foi realizado o carregamento das bases de acidentes, segurança pública, logradouros, bairros e rede cicloviária, com a padronização dos nomes das colunas, dos tipos de dados e a seleção apenas das variáveis relevantes para a análise. O principal desafio dessa etapa foi a heterogeneidade das bases utilizadas, que apresentavam diferenças de estrutura, granularidade e nomenclatura dos locais. Foram necessárias diversas etapas de limpeza, transformação e engenharia de atributos, através de tentativa e erro, com o objetivo de chegar a dados conclusivos o suficiente para uso de métodos e criação de análises.

A limpeza dos dados foi feita para remover inconsistências e facilitar a integração entre as bases. As principais operações realizadas foram a remoção de duplicatas, espaços extras, e valores nulos, evitando linhas repetidas ao fazer operações de merge. Também foram realizados ajustes nos nomes das colunas para melhorar a compreensão dos dados, além da conversão de tipos de variáveis. As colunas referentes à quantidade de roubos, furtos e velocidade, por exemplo, estavam originalmente no formato float, apesar de todos os valores possuírem apenas zeros na casa decimal, sendo então convertidas para o tipo inteiro.

Foi feita também a padronização da capitalização das colunas com nomes de vias, logradouros e bairros, para caixa alta, facilitando operações entre tabelas, remoção de e registros

duplicados. Além disso, foram removidos valores inválidos, como logradouros sem nome e velocidades iguais a zero. Também foram identificados casos em que um mesmo logradouro aparecia múltiplas vezes devido à divisão das vias em diferentes trechos. Nesses casos, os dados foram consolidados para representar cada via de maneira única.

As bases apresentaram diferenças significativas na escrita de nomes de vias e logradouros, sendo necessário lidar com o uso de abreviações, diferenças de capitalização, presença de acentos, pontuação, pequenas variações ortográficas e erros de digitação antes de poder seguir com o processamento normal dos dados.

Para reduzir inconsistências, foi implementada uma função que resolve a maior parte desses problemas de padronização textual, removendo caracteres especiais, espaços duplicados e padronização de abreviações, como "Av." para "Avenida" ou "R." para "Rua".

Essa etapa permitiu melhorar significativamente a compatibilidade entre os registros das diferentes tabelas. Para as incompatibilidades não resolvidas na etapa anterior, uma outra camada de padronização foi aplicada sobre os dados, utilizando a estratégia de fuzzy matching, fazendo uma comparação aproximada de strings para achar equivalentes. Dessa forma, esse processo completo consistiu em realizar inicialmente um merge comum, lidando primeiro com os problemas mais simples, e então identificar registros que não tiveram correspondência e usar o fuzzy matching para fazer uma segunda tentativa de buscar o logradouro mais semelhante. Alguns dados, aproximadamente 8, ainda ficaram sem correspondência, mas a grande maioria foi encontrada.

Alguns datasets possuíam múltiplos registros para um mesmo bairro ao longo de diferentes anos ou para diferentes logradouros, sendo necessário realizar um processo de agregação por bairro antes de juntar as tabelas com o merge, de modo a evitar duplicações e a explosão do número de linhas. Para os valores de roubos e furtos e acidentes, foram calculadas as médias dos registros históricos para representar os dados consolidados.

As bases brutas já apresentavam registros incompletos, e após as operações de integração, ligando as tabelas por vias, logradouros e bairros, surgiram outros valores ausentes. O tratamento desses dados foi realizado de acordo com o significado de cada variável. Os scores de criminalidade, calculados a partir da soma ponderada das ocorrências de roubos e furtos, e os scores de acidentes, também obtidos por meio de pesos atribuídos aos tipos de acidentes de maior risco para ciclistas, foram preenchidos com valor zero quando não existiam registros associados. Já os fatores multiplicativos utilizados na fórmula final de cálculo do risco receberam valor neutro igual a 1, evitando que a ausência de determinadas informações anulasse completamente o score final. Essa abordagem permitiu preservar a consistência dos cálculos e garantir que o índice de risco representasse de forma mais adequada às condições reais de cada via.

Os scores calculados com base nos dados, para serem usados na fórmula do cálculo do índice geral de risco, apresentavam escalas muito distintas, dificultando a interpretação e comparação. Para resolver esse problema, foi aplicada normalização Min-Max, transformando os valores para uma escala de 0 a 100. Posteriormente, o índice de risco foi invertido para gerar um

índice de segurança, em que valores altos representam maior segurança e valores baixos representam maior risco.

Foram criadas novas variáveis derivadas a partir dos dados brutos com o objetivo de representar melhor os fatores de risco para ciclistas. Um dos atributos novos calculados foi o score de criminalidade, construído a partir das colunas de roubos de bicicleta e furtos de bicicleta do dataset de indicadores de segurança. Foram atribuídos pesos diferentes segundo a gravidade, com os roubos recebendo um peso 4, e furtos recebendo um peso 2. Outra variável calculada foi o score relacionado a acidentes e delitos, dados presentes na tabela de acidentes de trânsito por logradouro. Cada ocorrência recebeu um peso proporcional ao potencial risco para ciclistas. Assim, os pesos distribuídos foram: 1 para casos de acidentes, 3 para lesão corporal, 5 para atropelamentos e 10 para homicídio culposo. Para facilitar o cálculo do score e a criação de uma coluna com a soma de todos os tipos de acidentes, foi utilizada a técnica pivot, para transformar os dados do formato "longo" para "largo", modificando os dados com a quantidade de cada tipo de ocorrência que antes estavam em linhas, para cada um ser uma coluna.

Para os dados do banco de logradouros, foi criado a variável de peso da velocidade, a partir da velocidade regulamentada das vias, onde as vias com velocidades maiores receberam pesos mais altos por apresentarem maior risco potencial. Os pesos foram: 1 para velocidade de até 40 km/h, 1.2 para velocidades até 50 km/h, 1.5 para limites de até 60 km/h, 2 para velocidades abaixo de 70 km/h e 3 para valores acima de 70 km/h. Foi calculada a variável de peso de hierarquia com base na classificação de nível das vias, com vias estruturais e arteriais recebendo pesos superiores às vias locais, por oferecerem um risco maior aos ciclistas.

Por fim, foi desenvolvido um índice de risco composto integrando:

- criminalidade contra ciclistas (variável score_c, com valores vazios preenchidos com 0);
- acidentes/delitos (variável score_d, com valores vazios preenchidos com 0);
- velocidade máxima de via (variável peso_v, com valores vazios preenchidos com 1);
- hierarquia de via (variável peso_v, com valores vazios preenchidos com 1);
- segurança da infraestrutura cicloviária de via (safety_score_final_v2, com valores vazios preenchidos com 0).

A fórmula aplicada para calcular o score geral de risco foi:

[(score_c + score_d) * peso_v * peso_h] + peso_infra

Os valores da variável de segurança da infraestrutura cicloviária "safety_score_final_v2" foram invertidos para ele virar um índice de risco e ser compatível com os outros índices, onde o valor mais alto é o de mais risco. O cálculo feito foi:

peso_infra = 10 - safety_score_final_v2

Após essa apuração, o score de risco resultante foi, então, transformado para um score de segurança, posteriormente utilizado para classificar as vias segundo níveis de segurança para ciclistas.

Figura 3 - Modelo entidade-relacionamento (MER) da base de dados utilizada no projeto

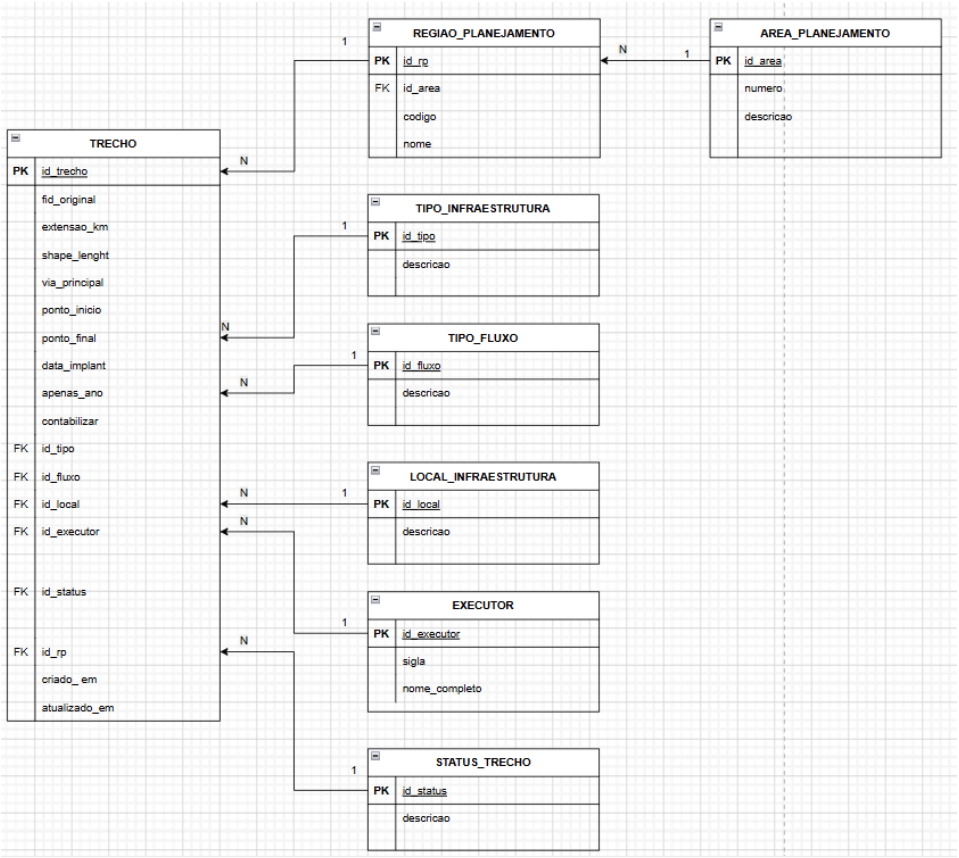

Figura 4 - Matriz de correlação entre variáveis espaciais e estruturais da malha cicloviária utilizada na análise exploratória dos dados

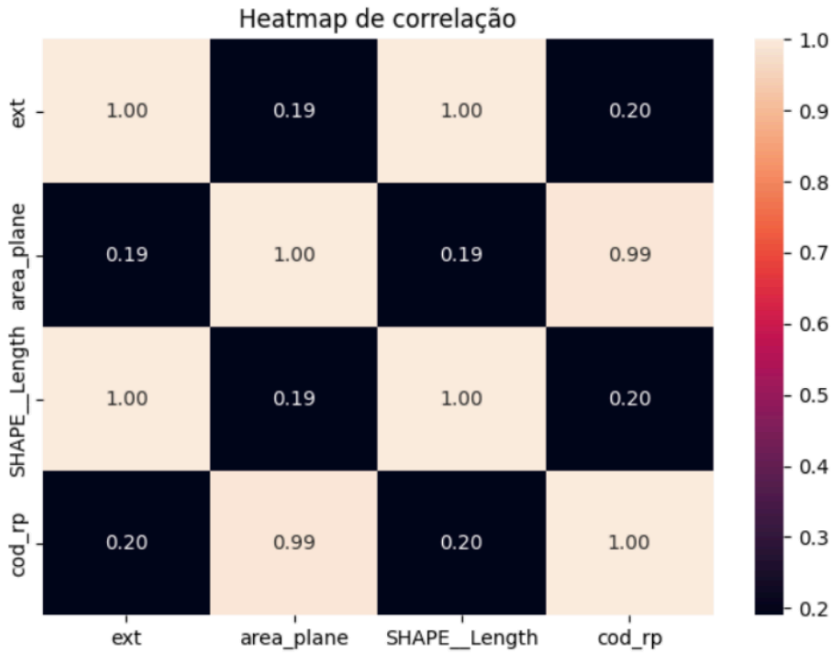

4. Métodos

Responsáveis pela seção: Caroline Yumi, Mariana Freitas e Pedro Portela

O modelo foi construído a partir da combinação de três componentes: o nível de risco associado a acidentes de trânsito, o nível de risco associado a crimes envolvendo bicicletas e os pesos estruturais das infraestruturas urbanas. A partir dessas análises, foi gerada uma pontuação final de risco normalizada, posteriormente convertida em uma escala de segurança e categorizada em níveis para interpretação dos resultados.

Inicialmente, os datasets foram carregados e submetidos a etapas de limpeza e padronização textual, incluindo normalização de nomes de bairros e logradouros, remoção de duplicidades e eliminação de registros inválidos. Após tal apuração, foram realizados tratamentos específicos em cada base, como filtragem temporal dos dados, seleção das variáveis relevantes e conversão de tipos numéricos. Para melhorar a integração entre os datasets, foi aplicada uma padronização dos nomes das vias e utilizado um processo de correspondência aproximada (fuzzy matching) para associar logradouros com grafias semelhantes.

Após a integração das tabelas por bairro e logradouro, foram criados indicadores relacionados à segurança e ao risco viário. Entre eles estão o score_d, baseado em acidentes de trânsito, o score_c, relacionado a roubos e furtos de bicicletas, além dos pesos associados à velocidade máxima das vias (peso_v) e à hierarquia viária (peso_h). Assim, esses indicadores foram combinados para gerar o score_risco de cada trecho cicloviário. O resultado foi normalizado e convertido em categorias qualitativas de segurança, permitindo classificar as vias em diferentes níveis de risco para análise e visualização geoespacial.

Posteriormente, foi utilizado o método de Machine Learning K-Means para descobrir padrões, encontrar classificações naturais para os dados, fazer análises e comparar com o score de risco calculado com a fórmula que utiliza heurísticas para gerar a tabela final das vias e suas classificações de segurança. A clusterização foi realizada utilizando as variáveis 'score_c', 'score_d', 'peso_v', 'peso_h', 'peso_infra', 'velocidade_maxima' e 'extensao_metros'.

Os dados foram normalizados utilizando StandardScaler, evitando que variáveis com magnitudes maiores afetassem exageradamente o processo de agrupamento e foram definidos 5 clusters para a realização do método inicialmente.

A linguagem utilizada para o algoritmo do método K-Means foi Python, utilizando as bibliotecas Pandas, NumPy, Scikit-learn e Matplotlib. O desenvolvimento foi feito inteiramente no ambiente do Google Collab, no arquivo kmeans.ipynb, com datasets brutos baixados em csv.

Os hiperparâmetros principais utilizados no código do K-Means foram o número de clusters n_clusters = 5 e a variável de inicialização aleatória random_state = 42.

A avaliação do modelo foi realizada principalmente por meio de análise exploratória e interpretação dos agrupamentos gerados, Para isso foram utilizadas as médias dos clusters, boxplots de cada variável, heatmaps e distribuição das variáveis.

Quanto à comparação qualitativa entre o score de risco heurístico desenvolvido manualmente e os clusters identificados com aprendizado de máquina pelo algoritmo K-Means.

Os resultados indicaram que a abordagem de clusterização foi capaz de identificar padrões urbanos mais diversos e equilibrados em relação ao método heurístico calculado manualmente, que teve uma grande quantidade de registros com classificação de alta segurança, em relação às outras classes.

A justificativa para o algoritmo K-Means se dá por sua simplicidade de uso, precisando de mínimas informações para gerar resultados interessantes para serem analisados, além disso como o objetivo do projeto se trata da classificação de dados, esse método se tornou a escolha mais atrante considerando sua capacidade de identificar padrões em bases multidimensionais sem necessidade de rótulos previamente definidos.

Dada a etapa de machine learning observamos que os boxplots por variável mostram os principais fatores de separação entre os clusters sendo o score_c e score_d apresentando alta variância entre grupos. O heatmap nos mostrou as principais correlações entre as variáveis onde o cluster de alto risco criminal concentrou os maiores valores de score_c e score_d, o cluster infraestrutura inadequada tem um alto peso_infra com scores criminais moderados e o cluster Baixo risco apresentou os menores valores em todas as dimensões, correspondendo a maioria das vias analisadas.

O gráfico de distribuição de vias por cluster confirmou que o grupo Baixo risco é o mais numeroso, o que é esperado dado que a malha viária do Rio de Janeiro é composta majoritariamente por vias locais e residenciais. Por fim, o pair plot com coloração por cluster demonstrou uma separação razoável entre os grupos, especialmente nos pares score_c com score_d e peso_v com velocidade_maxima, validando a qualidade da segmentação produzida pelo modelo.

Figura 5 - Gráfico de Boxplot da variável "score_c"

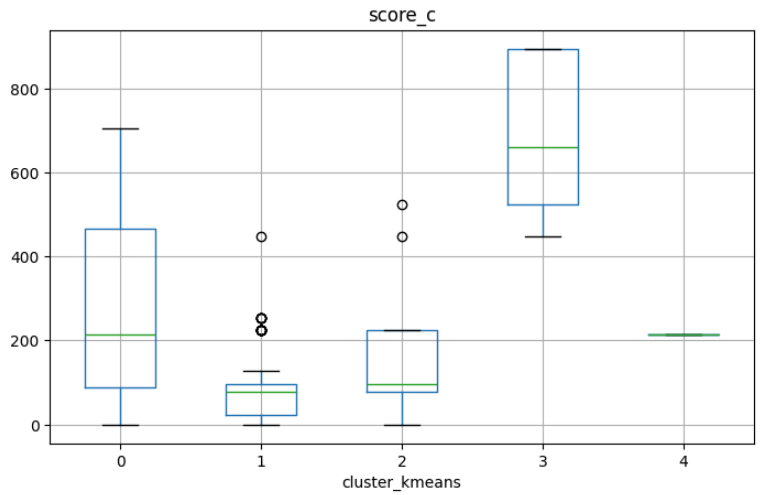

Figura 6 - Gráfico de Boxplot da variável "score_d"

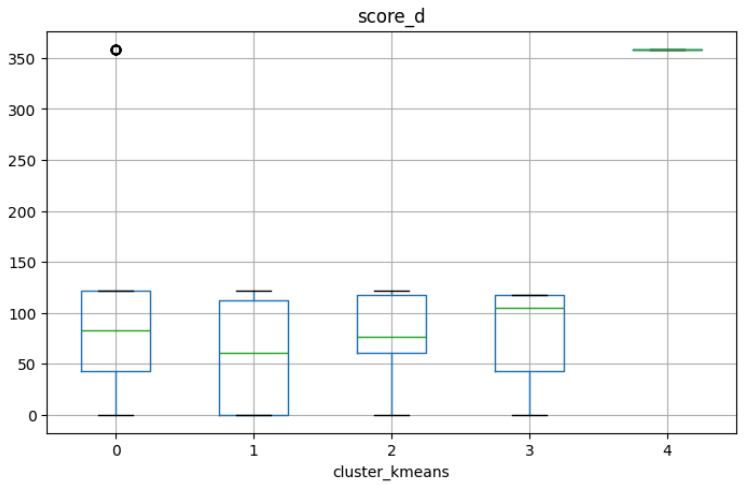

Figura 7 - Gráfico de Heatmap das médias dos clusters

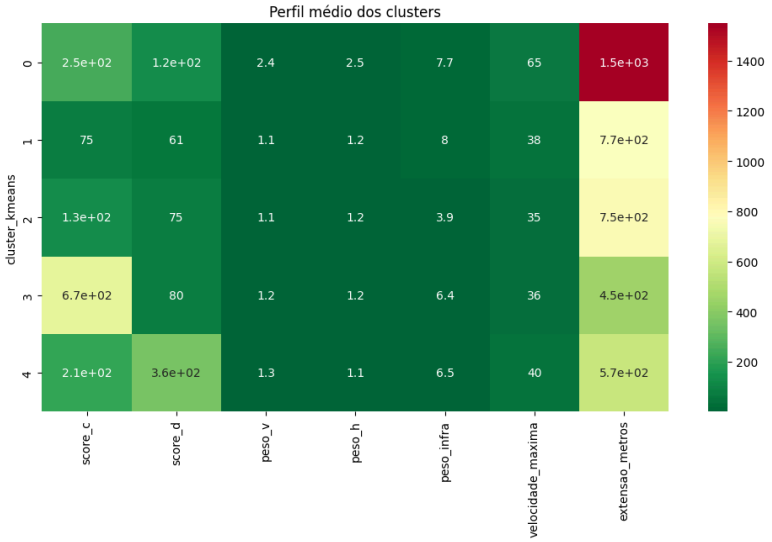

Figura 8 - Gráfico de PairPlot

Figura 9 - Gráfico de distribuição de vias por cluster

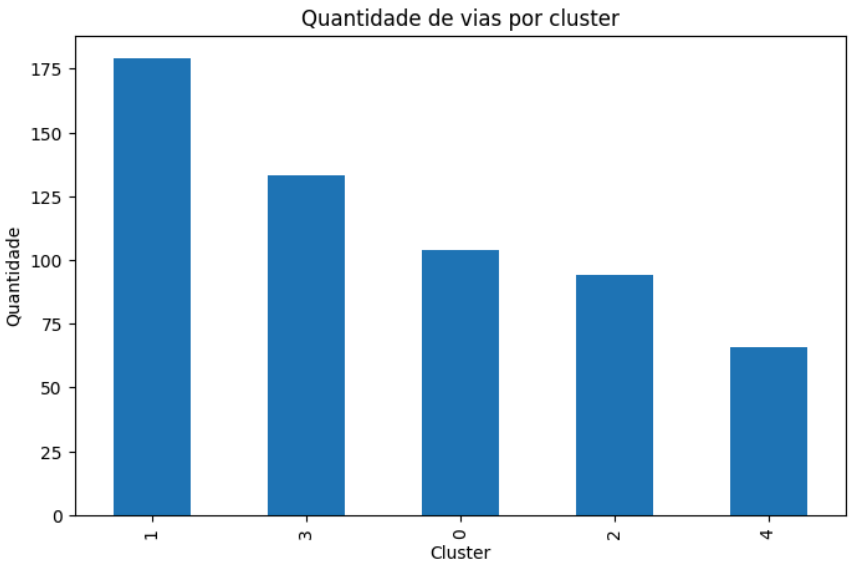

5. Conclusão

Responsável pela seção: Mariana Freitas

A partir da análise de dados sobre acidentes de trânsito e infraestrutura cicloviária, foi possível identificar regiões de maior risco e compreender como a desigualdade na infraestrutura das ciclovias impacta diretamente a experiência dos usuários de bicicleta.

Os resultados obtidos demonstram que o uso da tecnologia e a análise de dados podem auxiliar na construção de soluções específicas para a mobilidade urbana sustentável, permitindo a criação de rotas que priorizem a segurança dos ciclistas sem desconsiderar a praticidade dos deslocamentos cotidianos. O projeto, entretanto, possui limitações relacionadas à atualização dos dados e à dificuldade de representar, em tempo real, mudanças no trânsito e nas condições das vias. Ainda assim, a proposta estabelece uma base relevante para futuras melhorias e ampliações, como a integração de informações em tempo real, o uso de inteligência artificial e a participação colaborativa dos próprios ciclistas.

Além da aplicação voltada aos usuários, o sistema também pode auxiliar órgãos públicos e gestores urbanos na identificação de áreas que necessitam de investimentos em infraestrutura cicloviária, sinalização e segurança pública. A análise dos dados permite reconhecer padrões de risco e regiões críticas, contribuindo para a formulação de políticas públicas voltadas à mobilidade sustentável e à redução de acidentes envolvendo ciclistas.

Dessa forma, o projeto evidencia como a integração entre dados urbanos e tecnologia pode contribuir para cidades mais seguras, acessíveis e sustentáveis, incentivando o uso da bicicleta como meio de transporte e promovendo uma melhor qualidade de vida para a população.

Figuras 10, 11 e 12 - Modelo do protótipo do site

Figura 10 - Tela inicial do protótipo com opções de filtro para personalização das informações

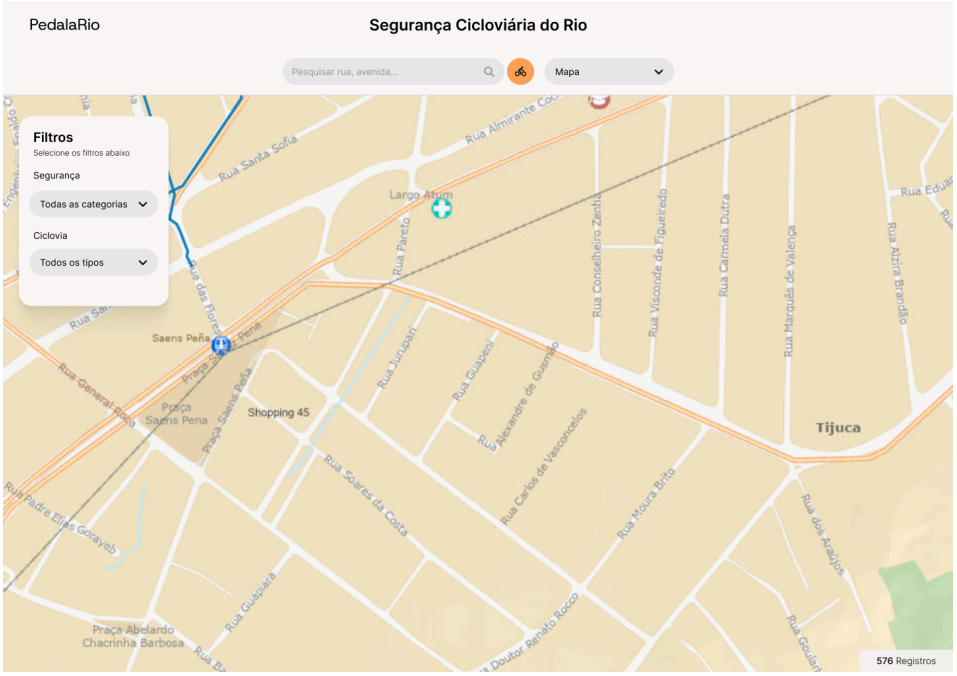

Figura 11 - Ferramenta para inserção do ponto de partida e chegada, permitindo o cálculo da trajetória mais segura

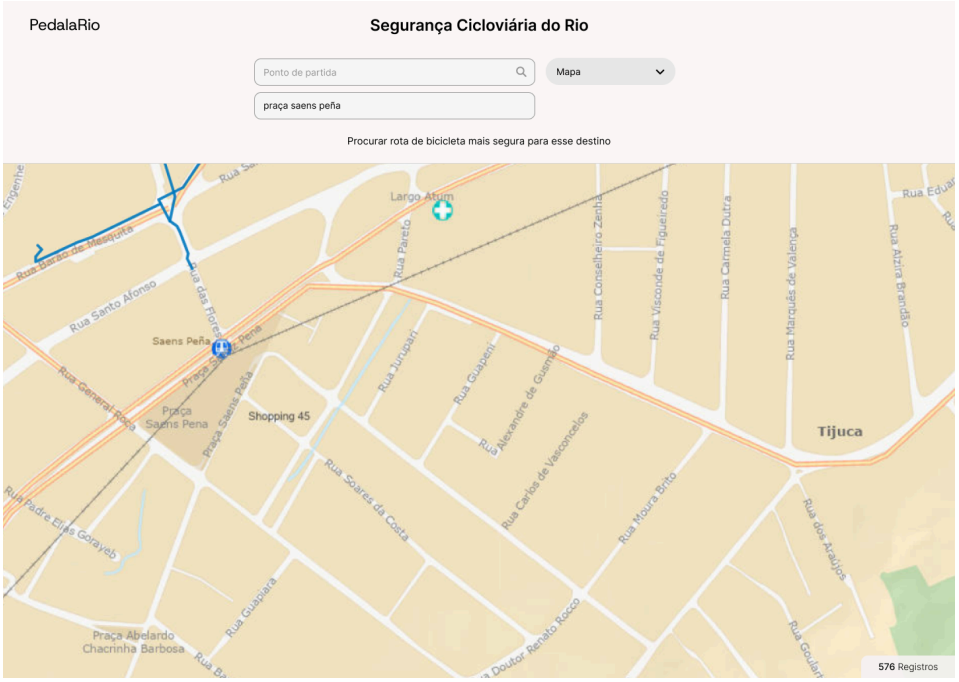

Figura 12 - Área destinada ao ranking de segurança das vias cicloviárias do Rio de Janeiro

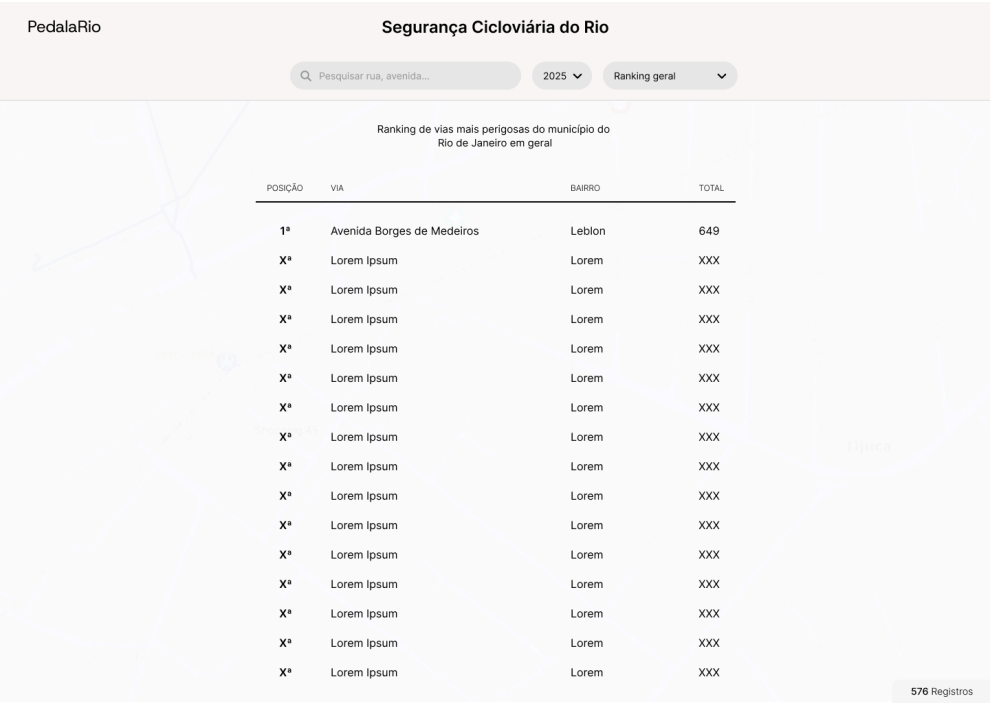

POSIÇÃO	VIA	BAIRRO	TOTAL
1ª	Avenida Borges de Medeiros	Leblon	649
Xª	Lorem Ipsum	Lorem	XXX
Xª	Lorem Ipsum	Lorem	XXX
Xª	Lorem Ipsum	Lorem	XXX
Xª	Lorem Ipsum	Lorem	XXX
Xª	Lorem Ipsum	Lorem	XXX
Xª	Lorem Ipsum	Lorem	XXX
Xª	Lorem Ipsum	Lorem	XXX
Xª	Lorem Ipsum	Lorem	XXX
Xª	Lorem Ipsum	Lorem	XXX
Xª	Lorem Ipsum	Lorem	XXX
Xª	Lorem Ipsum	Lorem	XXX
Xª	Lorem Ipsum	Lorem	XXX
Xª	Lorem Ipsum	Lorem	XXX
Xª	Lorem Ipsum	Lorem	XXX
Xª	Lorem Ipsum	Lorem	XXX

6. Referências

PREFEITURA DA CIDADE DO RIO DE JANEIRO. *Rede cicloviária implantada*. Rio de Janeiro: Data.Rio, [s.d.]. Disponível em: https://www.data.rio/datasets/PCRJ::rede-cicloviária-implantada/about.

ZENODO. *CiclistasAcidentes_BR_2018_2024.csv*. [S. l.], 2025. Disponível em: https://zenodo.org/records/16279880?preview_file=CiclistasAcidentes_BR_2018_2024.csv.

SECRETARIA MUNICIPAL DE SAÚDE DO RIO DE JANEIRO. *Painel de acidente de transporte terrestre*. Rio de Janeiro, [s.d.]. Disponível em: https://epirio.svs.rio.br/painel/acidente-de-tranporte-terrestre/.

PREFEITURA DA CIDADE DO RIO DE JANEIRO. Secretaria Municipal de Transportes. *CicloRio: plano de expansão cicloviária*. Rio de Janeiro, 2022. Disponível em: https://transportes.prefeitura.rio/wp-content/uploads/sites/31/2022/07/CicloRio-Plano-de-Expansa%CC%83o-Ciclovia%CC%81ria-transportes.pdf.

INSTITUTO DE SEGURANÇA PÚBLICA DO RIO DE JANEIRO. *ISPGeo*. Rio de Janeiro, [s.d.]. Disponível em: https://www.rj.gov.br/isp/node/739.

INSTITUTO DE SEGURANÇA PÚBLICA DO RIO DE JANEIRO. *Estatísticas de segurança pública*. Rio de Janeiro, [s.d.]. Disponível em: https://www.ispdados.rj.gov.br/estatistica.html.

PREFEITURA DA CIDADE DO RIO DE JANEIRO. *Limite de bairros*. Rio de Janeiro: Data.Rio, [s.d.]. Disponível em: https://www.data.rio/datasets/PCRJ::limite-de-bairros/about.